UNIVERSIDAD YACHAY TECH

Maestría en Ciencia de Datos

Predicción de alertas de desnutrición infantil

Evaluación comparativa de modelos de aprendizaje automático y análisis estocástico

Asignatura

Fundamentos de Inteligencia Artificial

Autor

Mat. Héctor Alexander Román Potosí

Docente

Ph.D. Manuel Eugenio Morocho Cayamcela

Examen de medio semestre – IISEM2026

31 de octubre de 2026

Resumen

Este trabajo estudia un problema de clasificación binaria de alertas de desnutrición infantil en Ecuador mediante un conjunto de datos sintético de 70 000 observaciones de entrenamiento y 30 000 observaciones de prueba.

Se evaluaron clasificadores lineales, ensambles de árboles, Gradient Boosting, una red neuronal multicapa y enfoques probabilísticos. Se priorizó la exactitud (*accuracy*), métrica oficial de la competencia.

Los experimentos no identificaron una mejora reproducible frente al clasificador de clase mayoritaria, cuyo accuracy en validación fue aproximadamente del 89.99 %.

La solución enviada a Kaggle mediante Random Forest alcanzó un accuracy público de 91.1255 %. Sin embargo, todas sus predicciones fueron de clase cero, por lo que su desempeño equivale al baseline.

Se presenta una interpretación estadística de este resultado y se discuten las limitaciones del conjunto sintético y de la evaluación mediante accuracy.

Palabras clave: clasificación binaria, Random Forest, XGBoost, desbalance de clases, inferencia estocástica, accuracy, Kaggle.

Índice

1. Introducción **2**

1.1. Objetivo general 2

1.2. Objetivos específicos 2

2. Descripción de los datos **2**

2.1. Distribución de clases 3

2.2. Calidad de los datos 3

3. Metodología **3**

3.1. Preparación 3

3.2. Métrica principal 3

3.3. Modelo de referencia 3

3.4. Modelos estudiados 4

4. Resultados experimentales **4**

4.1. Validación cruzada 4

4.2. Comparación competitiva 4

4.3. XGBoost 4

4.4. Red neuronal 4

5. Análisis matemático y estocástico **5**

5.1. Regla bayesiana 5

5.2. Modelo beta-binomial 5

5.3. Modelo Probit 5

6. Comprobación de generalización **6**

7. Resultado de Kaggle **6**

7.1. Puntuación pública 6

8. Discusión **7**

9. Conclusiones **7**

1. Introducción

La identificación de alertas de desnutrición infantil constituye una tarea de clasificación supervisada. A partir de características individuales se busca estimar una variable de respuesta binaria.

El presente trabajo utiliza un conjunto sintético publicado para la competencia académica *Ecuador Infant Malnutrition Competition (IISEM2026 MCD)*.

Es importante distinguir la naturaleza académica de estos datos de una herramienta clínica: las etiquetas sintéticas no equivalen a diagnósticos médicos verificados.

1.1. Objetivo general

Comparar diversos modelos de aprendizaje automático para maximizar la exactitud de clasificación sobre datos no observados, aplicando procedimientos reproducibles de entrenamiento y validación.

1.2. Objetivos específicos

- Examinar la estructura y calidad de los datos.
- Construir un baseline de clase mayoritaria.
- Comparar algoritmos de distintas familias.
- Evaluar el efecto del desbalance y los umbrales.
- Estudiar una explicación probabilística del rendimiento observado.
- Generar una entrega válida para Kaggle.

2. Descripción de los datos

La base de entrenamiento contiene 70 000 registros y seis variables predictoras:

Variable	Descripción
`edad_meses`	Edad en meses
`sexo`	Categoría de sexo
`region`	Región geográfica
`nivel_educacion_madre`	Escolaridad materna
`peso_kg`	Peso en kilogramos
`talla_cm`	Talla en centímetros

La variable objetivo es `alerta_desnutricion`, con valores cero y uno.

2.1. Distribución de clases

Se observaron 62 991 registros de clase cero y 7 009 de clase uno:

$$P(Y = 0) \approx 0{,}899871, \qquad P(Y = 1) \approx 0{,}100129.$$

Existe, por tanto, un importante desbalance de clases.

2.2. Calidad de los datos

Se identificaron valores faltantes en `peso_kg` (aproximadamente 4.96 %) y `talla_cm` (aproximadamente 10.07 %).

También se observaron 3 921 edades negativas y 3 163 edades superiores a 24 meses.

Estas anomalías se analizaron sin eliminar arbitrariamente observaciones etiquetadas.

3. Metodología

3.1. Preparación

Se utilizó imputación de mediana en las variables numéricas y codificación One-Hot para las categóricas.

El preprocesamiento se incorporó dentro de `Pipeline` y `ColumnTransformer` para impedir que los estadísticos de validación intervinieran en el ajuste de entrenamiento.

3.2. Métrica principal

La métrica oficial es:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}.$$

Se calcularon además recall, F1, ROC-AUC y balanced accuracy como métricas diagnósticas.

3.3. Modelo de referencia

El clasificador de clase mayoritaria predice:

$$\widehat{Y}(x) = 0.$$

Su exactitud esperada se aproxima a la proporción de observaciones pertenecientes a la clase cero.

3.4. Modelos estudiados

Se experimentó con DummyClassifier, regresión logística, Random Forest, Extra Trees, HistGradientBoosting, LightGBM, CatBoost, XGBoost y una red neuronal MLP.

Adicionalmente se analizaron probabilidades beta-binomiales y un modelo estocástico Probit.

4. Resultados experimentales

4.1. Validación cruzada

En tres particiones estratificadas se obtuvieron:

Modelo	Accuracy	Recall	ROC-AUC
Dummy	0.89987	0.00000	0.50000
Random Forest	0.89987	0.00000	0.65429
HistGradientBoosting	0.89987	0.00000	0.65474
RF balanceado	0.45807	0.85633	0.65305
HGB balanceado	0.42281	0.92338	0.65003

Los modelos balanceados incrementaron el recall de la clase positiva, pero redujeron notablemente la exactitud, por lo que no fueron seleccionados para la métrica de la competencia.

4.2. Comparación competitiva

En un torneo adicional se evaluaron Random Forest, Extra Trees, LightGBM y CatBoost.

Ninguna configuración superó el accuracy del clasificador mayoritario.

La auditoría de las predicciones con mayor riesgo tampoco encontró grupos con una precisión suficientemente alta para justificar el cambio de cero a uno.

4.3. XGBoost

Se realizó una evaluación mediante cinco particiones estratificadas.

El accuracy global fuera de muestra por fold (*out-of-fold*) fue:

$$A_{\mathrm{XGB}} = 0{,}899871.$$

El ROC-AUC global fue aproximadamente 0.653106.

Los cinco folds predijeron exclusivamente la clase cero con el umbral 0.5.

4.4. Red neuronal

Una red neuronal MLP con capas ocultas de 32 y 16 neuronas obtuvo ROC-AUC aproximado de 0.599958, sin mejorar el accuracy de la clase mayoritaria.

5. Análisis matemático y estocástico

5.1. Regla bayesiana

Para una clasificación binaria con igual costo para ambos tipos de error, la regla óptima según accuracy es:

$$\widehat{y}(x) = \begin{cases} 1, & P(Y = 1 \mid X = x) > 0{,}5, \\ 0, & P(Y = 1 \mid X = x) \leq 0{,}5. \end{cases}$$

Por tanto, un modelo puede discriminar probabilidades sin que ello produzca predicciones positivas.

5.2. Modelo beta-binomial

Se estimaron proporciones condicionales de alerta por región y escolaridad materna mediante una distribución beta-binomial.

El modelo obtuvo ROC-AUC aproximado de 0.630545 y Brier Score de 0.087296.

Ninguno de los grupos analizados presentó una probabilidad posterior media cercana a 0.5.

5.3. Modelo Probit

Para estudiar el carácter estocástico de las etiquetas, se planteó:

$$Z = r(X) + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, 1),$$

con regla de etiquetado determinada por un umbral c. En esa aproximación:

$$P(Y = 1 \mid X = x) = \Phi(r(x) - c),$$

donde Φ es la función de distribución acumulada normal estándar.

El experimento estimó:

$$\widehat{c} = 1{,}065837, \qquad \max_x \widehat{P}(Y = 1 \mid X = x) = 0{,}143249.$$

El Probit obtuvo ROC-AUC 0.649634 y Brier Score 0.086889.

Como la función de riesgo reconstruida cumple $r(x) \leq 0$, este modelo estima probabilidades inferiores a 0.5 para todas las observaciones.

Limitación: la reconstrucción del mecanismo generador es aproximada. Este resultado no prueba que ningún algoritmo imaginable pueda superar el baseline sobre cualquier muestra.

6. Comprobación de generalización

Se compararon las distribuciones de las variables predictoras entre entrenamiento y prueba.

Un clasificador entrenado para distinguir ambos conjuntos obtuvo:

$$\text{ROC-AUC}_{\text{origen}} = 0{,}495746.$$

No se detectó una separación importante entre las características observadas de los dos conjuntos.

La estimación beta-binomial del accuracy de predecir siempre cero sobre el test completo fue:

$$\widehat{A}_{\text{test}} = 0{,}899172.$$

El intervalo predictivo aproximado al 95 % fue de 89.5161 % a 90.3182 %.

Este intervalo depende de los supuestos del modelo utilizado y no constituye garantía de la puntuación final.

7. Resultado de Kaggle

El modelo Random Forest se entrenó sobre las 70 000 observaciones etiquetadas y generó 30 000 predicciones.

El archivo entregado cumplió la estructura:

`ID, alerta_desnutricion`

Las 30 000 predicciones fueron cero.

7.1. Puntuación pública

La plataforma registró el envío con referencia `57815647` y obtuvo:

$$\boxed{\text{Accuracy}_{\text{publico}} = 0{,}911254675280}$$

Esto equivale a aproximadamente 91.1255 % de exactitud sobre la fracción pública.

Interpretación: dado que las predicciones fueron todas cero, esta puntuación es exactamente la del baseline constante y no evidencia una mejora de Random Forest frente a DummyClassifier.

La puntuación privada no estaba disponible en el momento de documentar el resultado.

8. Discusión

Los resultados muestran que aumentar la complejidad del modelo no produjo ganancias de accuracy bajo los protocolos evaluados.

El fuerte desbalance de clases y el mecanismo estocástico sintético proporcionan una explicación coherente para esta observación.

El ROC-AUC superior a 0.5 en diversos modelos indica cierta capacidad de ordenación de riesgos, pero no es suficiente para obtener más aciertos al aplicar el umbral convencional.

El resultado de 91.1255 % corresponde a una métrica de competencia sobre datos sintéticos. No debe interpretarse como una validación de utilidad clínica del modelo.

9. Conclusiones

1. Se construyó un flujo reproducible de clasificación supervisada.
2. Se analizaron problemas de calidad, desbalance y posibles anomalías.
3. Se compararon distintas familias de modelos, incluyendo aprendizaje profundo y enfoques probabilísticos.
4. Ningún modelo demostró una mejora consistente de accuracy frente a la clase mayoritaria.
5. El análisis estocástico permitió formular una explicación matemática del comportamiento de los clasificadores.
6. Se generó y validó una submission oficial con accuracy público de 91.1255 %.

Reproducibilidad

Se adjuntan el notebook ejecutable, los scripts de experimentación, los resultados principales, los archivos oficiales de entrada y la evidencia de la participación en Kaggle.

No se emplearon etiquetas ocultas del test para ajustar, seleccionar o evaluar los modelos.

Referencias

[1] Breiman, L. (2001). *Random Forests.* Machine Learning, 45, 5–32.

[2] Grinsztajn, L., Oyallon, E. y Varoquaux, G. (2022). *Why do tree-based models still outperform deep learning on typical tabular data?* NeurIPS.

[3] McElfresh, D. y colaboradores (2023). *When Do Neural Nets Outperform Boosted Trees on Tabular Data?* NeurIPS.

[4] Morocho Cayamcela, M. E. *ArtificialIntelligence: repositorio académico y generador de datos sintéticos.* https://github.com/eugeniomorocho/ArtificialIntelligence